X光工具云服务器部署未成功 — 原因分析报告

- **报告日期**：2026-10-13
- **涉及环境**：公网云服务器验证环境（NFS Server 3.1，glibc 2.17），六工具裸机部署（`/opt/agent/vision-agent/tools/<tool>`，systemd `ai-tool@<tool>`，端口 18101-18106）
- **结论**：X光（DR）真实工具**未上线**，平台侧维持 mock 端点（`dr_defect_detection_v1`，18101）。根因为**交付 API 不符合《统一 API 接入规范 V1.0》，被打回返工**，叠加**依赖 wheel 与现网 glibc 基线不匹配导致装不上**，属双重阻塞。

一、背景

六工具（孔探 / 热喘 / 荧光 / 金相 / X光 / 断口）由不同厂商分别交付，统一通过 `deploy/install_ai_tool.sh` 裸机安装、HTTP API 与 quality-agent 平台集成。
云服务器部署完成后，孔探、热喘、荧光三个工具成功跑上真实模型并通过 E2E；
X光未部署成功，断口则因交付包缺失同样为 mock（原因与本项无关，单独催办中）。

二、根因分析

2.1 主因：接口不合规（需返工，🔴 阻塞级）

对照《动力所工业图像智能算法工具统一 API 接入规范 V1.0》，X光交付物（`DRStructure_OPI_API_最终交付_20260914`）存在 3 处硬冲突 + 2 处卫生项：

类别	问题	违反条款	影响
A. 输入契约	`/api/v1/inference` 只接受专有 `.opi` 序列文件（`read_opi` 断言 2048×2048），不支持 JPEG/PNG/TIFF 标准图像	§6	平台/前端发送的是单张标准图，**根本喂不进数据**
A. 输入契约	仅支持多帧 `images` 字段，无单张 `image` 字段	§5.2	与平台现行调用方式不匹配
B. 响应外壳	结果埋在 `data` 下，缺顶层 `result` / `tool` / `input` / `performance`	§7 / §7.1	平台只能用临时兜底 `transform_dr_structure`，不可长期依赖
C. 产物取回	`artifacts` 只给文件名，无可直接访问的 `uri`，需另调 `GET /api/v1/results/{request_id}/{name}`	§7.2	前端无法直接展示标注图/间隙图/报告

类别	问题	违反条款	影响
D. 错误码	"图像不合法"统一回 1001/422，未按 1002/415、1004/422、1001/400 拆分	§8	卫生项
F. 交付物	样例仅 `.opi`，无标准图像样例及一一对应的期望输出 JSON	§15	无法做合规回归验收

> 即便解决环境问题装上依赖，A/C 两类不解决则**既进不来也拿不走产物**，
> 依然接不进前端流程——这是"接口返工"与"装不上"两个独立维度的阻塞。

2.2 次因：运行环境基线不匹配（E类，🟠 阻塞级）

- 交付离线锁中 `pillow==12.3.0`、`contourpy==1.3.3` 为 `manylinux_2_27/2_28` wheel；
- 现网云服务器为 NFS Server 3.1（**glibc 2.17**），wheel 即使下载成功也会因 ABI 不匹配在 import 时崩溃；
- 解决路径二选一：
  1. 交付方提供 cp311 的 `manylinux_2_17/2014` 版本（如 pillow 10.4.0、contourpy 1.1.1）；
  2. 在填报表明确声明"最低 glibc 2.28"，待方德 V4.0 环境到位后部署。

三、六工具横向对照（当时状态）

工具（端口）	接口合规	glibc 2.17 可装	上线状态	阻塞项
孔探 borescope (18104)	🟢 合规	🟢	✅ 真实模型已上线，前端 E2E 通过	无
热端 infrared (18105)	🟢 合规范例	🟢	✅ 真实模型已上线（systemd 托管）	仅剩切端点 + E2E 收尾
荧光 fpi (18106)	🟢 合规	🟢	✅ 真实模型服务	无
X光 dr (18101)	**🔴 不合规，7 条返工**	**🟠 需降级 2 个 wheel**	**⛔ mock**	接口返工 + wheel 降级（**双重阻塞**）
金相 metallography (18103)	🟢 合规	🟢	✅ 真实模型服务	无
断口 fracture	⚠️	⚠️	⛔ mock	交付包缺失，催办中

区分要点：金相是"接口最规范但环境装不上"；X光是"接口返工 + 环境需降级"双重问题——两者阻塞性质不同，不应混谈（参见 `deploy/容器化离线部署指南.md` 开头的醒目提示）。

四、当时的处置

1. X光能力注册保持指向 **mock 端点**（18101，`dr_defect_detection_v1`），不阻塞平台整体演示；
2. 出具《X光接口返工单》（2026-10-05），以热端 API 实测返回为合规范例逐字段对照，发给开发方返工；
3. 平台侧保留 `transform_dr_structure` 临时兜底，明确标注不作为长期依赖；
4. Runbook 验收记录中如实登记「X光 mock（接口返工）」。

五、返工后回归验收标准

1. 用标准图像（png/jpg/tif）单张 POST `/api/v1/inference`，返回 §7 顶层外壳，`result.status` 为 `normal/abnormal`；
2. `artifacts[]` 每项 `uri` 可被 HTTP 直接取回；
3. 提供 cp311 `manylinux_2_17` 的 pillow/contourpy wheel，在 glibc 2.17 干净机 `import` 通过；
4. 错误输入分别命中 1002/415、1004/422、1001/400；
5. 附期望输出 JSON，与样例一一对应。

验收通过后：`install_ai_tool.sh dr` 安装就位 → `switch_tool_endpoint.sh` 将 `dr_defect_detection_v1` 从 mock 切至真实端点 → 跑 dr 场景 E2E 出结论。

六、参考材料

- `六工具上交API/X光接口返工单.md`（返工清单与合规对照，2026-10-05/06）
- `quality-agent/deploy/容器化离线部署指南.md`（glibc 基线与"返工 vs 环境"两维度区分）
- `quality-agent/deploy/园区网离线部署Runbook.md`（六工具 mock/真实登记）
- `quality-agent/deploy/ai-tools/README.md`（端口与能力映射拓扑）
- 《中国航发动力所工业图像智能算法工具统一 API 接入规范 V1.0》