智能质检 Agent 系统硬件资源填报

> 版本 V1.1 ｜ 2026-08-17 ｜ 口径对齐《工业图像智能算法工具技术信息及 API 接入填报模板 V1.0》06_CPU硬件资源
> 数值来源：本机容器化实测（2026-08-17，docker stats / docker images）＋各组件官方要求；未经负载测试的项标注"待补测"。

1. 测试环境声明

项	值
实测机器	Apple M5（10 物理核 / 10 逻辑线程，arm64），macOS 26.5，Docker Desktop
部署目标架构	x86_64（阿里云 POC → 客户内网）
运行时	Docker Engine + Compose v2；Python 3.12（backend / mock）

2. 分单元资源填报

2.1 智能质检主服务（backend + frontend + Postgres/pgvector）

填写项	填写值
CPU 架构	x86_64（arm64 已实测可运行）
实际性能测试 CPU 完整型号	Apple M5（本地）；x86_64 待阿里云部署演练复测
推荐物理核心数	4
CPU 指令集依赖	无特殊要求（I/O 密集型，无重数值计算）
是否依赖 Intel MKL/OpenMP	否
推理/工作线程数	uvicorn 单 worker + async 事件循环
线程数是否可配置	是，uvicorn --workers
推荐内存	8 GB
磁盘空间	70 GB

填写项	填写值
OS	**Ubuntu 22.04**
运行时	预装 **Docker**（Engine + Compose v2）
带宽	**3 Mbps**

2.2 RAGFlow 全套（server + task executor + MySQL + Redis + ES + MinIO，第三方组件）

填写项	填写值
CPU 架构	x86_64（官方维护镜像）
推荐物理核心数	8（解析 + 检索并发工况）
CPU 指令集依赖	无特殊要求；ES 与文档解析受益于主流服务器指令集
推荐内存	32 GB（生产口径）
常驻内存	实测 7.4 GB（主容器 4.68 GB + ES 2.43 GB + MySQL/MinIO/Redis 0.29 GB，知识库近空）
单任务峰值内存	待补测（DeepDoc 解析大 PDF 时 executor 冲高）
磁盘空间	镜像约 14.6 GB（ragflow 11.8 GB + ES 1.3 GB + MySQL 1.3 GB + MinIO 227 MB）；含索引与文档存储建议 ≥100 GB
线程数是否可配置	是，task executor worker 数在 service_conf.yaml
NUMA/绑核要求	不适用
OS	**Ubuntu 22.04**
运行时	预装 **Docker**（Engine + Compose v2）
带宽	**3 Mbps**

2.3 MinerU（文档解析器，第三方组件）

填写项	填写值
显存	16 GB；

填写项	填写值
内存	24 GB
常驻内存	实测 4GB
磁盘空间	50 GB
Python 版本	3.10–3.13（与 backend 3.12 兼容）
CUDA	**13.0**
带宽	**3 Mbps**

3. 模型

3.1 模型清单

模型	类型	用途参考
`qwen3.8-max`	文本 LLM	Qwen-Max 档，主解读/生成
`qwen3.7-plus`	文本 LLM	Plus 档
`qwen3.7-flash`	文本 LLM	Flash 档（高效）
`qwen3-vl-embedding`	多模态向量嵌入	知识库入库/检索向量化
`qwen3-vl-rerank`	多模态重排	检索重排

企业版版本token plan页面（点我跳转）



> 购买团队高级版本

阿里云自定义服务器购买页面（点我跳转）


最近使用规格
全部规格
“帮我推荐实例规格”
筛选
选择 vCPU
选择内存
选择代际
模糊搜索规格名称，如ecs.e
查看更多规格参数
架构
X86 计算
Arm 计算
GPU
弹性裸金属服务器
高性能计算
全部分类
全部分类
T4加速
全部分类
全部分类
实例规格
规格族
GPU
GPU显存
可售可用区
架构-分类
参考价格
ecs.gn6i-c4g1.xlarge
GPU 计算型 gn6i
1 * NVIDIA T4
1 * 16 GB
29个可用区
GPU-T4加
¥3348.0/月
ecs.gn6i-c8g1.2xlarge
GPU 计算型 gn6i
1 * NVIDIA T4
1 * 16 GB
28个可用区
GPU-T4加
¥4032.0/月
ecs.gn6i-c16g1.4xlarge
GPU 计算型 gn6i
1 * NVIDIA T4
1 * 16 GB
26个可用区
GPU-T4加
¥4725.0/月
ecs.ebmgn6i.24xlarge
GPU 计算型弹性裸金属服务器 ebmgn6i
4 * NVIDIA T4
4 * 16 GB
10个可用区
GPU-T4加
¥19800.0/月
ecs.gn6i-c24g1.6xlarge
GPU 计算型 gn6i
1 * NVIDIA T4
1 * 16 GB
24个可用区
GPU-T4加
¥4950.0/月
ecs.gn6i-c40g1.10xlarge
GPU 计算型 gn6i
1 * NVIDIA T4
1 * 16 GB
23个可用区
GPU-T4加
¥7112.9/月
ecs.gn6i-c24g1.12xlarge
GPU 计算型 gn6i
2 * NVIDIA T4
2 * 16 GB
22个可用区
GPU-T4加
¥9900.0/月
ecs.gn6i-c24g1.24xlarge
售罄
GPU 计算型 gn6i
4 * NVIDIA T4
4 * 16 GB
12个可用区
GPU-T4加
¥19800.0/月


购买实例数量
1
购买时长
3 个月
比对模式
自动续费
启用自动续费
配置概要
保存为启动模板
付费类型 包年包月
地域 华北2（北京）
可用区 随机分配可用区
网络类型 专有网络
专有网络 默认专有网络
交换机 交换机选项不能为空
实例规格 GPU 计算型 gn6i / ecs.gn6i-c8g1.2xlarge (8 vCPU 31 GiB)
镜像 方德高可信服务器操作系统 V3.1
系统盘
ESSD云盘 100GiB
随实例释放
PL0（单盘IOPS性能上限1万）
自动快照策略：default_policy | 每天 | 保留 7 天 | 未开启跨地域复制
文件备份 激活备份
公网带宽 按固定带宽 3Mbps
安全组 默认安全组
登录凭证 自定义密码 - 请指定密码
标签 未绑定标签
实例名称 launch-advisor-20260818
元数据访问模式 普通模式和加固模式

> 注意，该服务器选购了T4GPU，配置概要并没有显示出来！